

Preuve de l'algorithme

Vocabulaire

On définit S comme le graphe représentant notre structure et M comme le graphe représentant notre motif.

Un motif approximé de M est un $\text{match}(a,b)$ tels que a soit isomorphe de M au degré de tolérance près.

Les sous-graphes d'un $\text{match}(a,b)$ sont les sous-graphes formés par l'ensemble des nœuds de a (pour le sous-graphe de structure) ou b (pour le sous-graphe de motif).

Un $\text{match}(a,b)$ est un ensemble d'association entre une arête de S et une arête de M .

Le degré de tolérance est le nombre maximal du nombre de différences entre les deux sous-graphes d'un match .

On distingue plusieurs différences: Type de liaison différente, Arêtes en plus, Arêtes en moins

Un $\text{match}(a,b)$ est un ensemble d'association entre une arête $a(i)$ appartenant à S et une arête $b(i)$ appartenant à M . Il est de taille i lorsque la taille de ses sous-ensembles est i

On agrandi un $\text{match}(a,b)$ lorsqu'on augmente les sous-ensembles a,b en ajoutant des associations de nouvelles arêtes de S avec de nouvelles arêtes de M (n'appartenant pas déjà à a et b)

Une solution (A,B) est un $\text{match}(A,B)$ où l'ensemble des nœuds composant les arêtes de a forme un sous-graphe de S considéré comme isomorphe avec notre motif en prenant en compte l'ensemble des degrés de tolérance. Alors A est un motif approximatif de M .

Un bon $\text{match}(a,b)$ est un sous-ensemble d'association d'arêtes tel qu'il existe une solution (A,B) avec:

a soit un sous-ensemble de A

b soit un sous-ensemble de B

les match de $a(i)$ et $b(i)$ sont identiques à ceux de $A(i)$ et $B(i)$

Un mauvais $\text{match}(a,b)$ est un sous-ensemble d'association n'étant un bon match d'aucune solution.

Preuve

Initialisation de l'algorithme:

Une arête de M est choisie par l'algorithme (arête de départ) , pour chaque arête de S on l'associe avec l'arête de départ dans un nouveau match.

On a forcément dans la liste de nos matchs tous les bons matchs existant de taille 1 ayant dans leurs ensemble b l'arête de départ.

Déroulement de l'algorithme:

A chaque itération on prend un match et une arête qui n'a pas été encore visitée par l'algorithme pour ce match.

L'association est écrite de la forme a_1, a_2 (arête de la structure) associé avec b_1, b_2 (arête du motif) avec a_1, a_2, b_1, b_2 des nœuds respectivement de S et M.

On va alors faire la liste de toutes les associations possibles (par encore faite) des arêtes de a_1 avec les arêtes de b_1 . On effectue de même pour a_2 et b_2 .

En faisant un produit de ces deux listes on obtient toutes les combinaisons d'association des arêtes de a_1 et a_2 avec les arêtes de b_1 et b_2 .

Pour chaque association possible calculé on crée un nouvel agrandissement du match sur lequel on itère en ajoutant aux sous ensembles les nouvelles arêtes associés.

Donc après une itération nous avons donc trouver toutes les possibilités d'agrandissement du match. Si c'est un bon match alors parmi toutes ces possibilités d'agrandissement, il se trouve un bon match de la même solution d'une taille plus grande.

Comme on va réitérer sur ce bon match agrandi de nouveau, alors on va l'agrandir à nouveau. Et ce jusqu'à qu'il soit un bon match avec des ensembles équivalents à ceux de sa solution.

Les mauvais matchs vont eux aussi s'agrandir jusqu'à que de nouveaux agrandissement ne soit possible (soit car on ne peut pas continuer le match, soit parce que les matchs continuer ont un degré de différence trop fort).

Si on peut étirer un mauvais match jusqu'à qu'il parvienne à être un motif approximé de M alors c'est une solution, donc par définition il ne peut être la résultante d'ancien mauvaismatch.

Comme les matchs n'interagissent pas entre eux, et que l'algorithme s'arrête lorsque tous les matchs sont traités, on est assuré de trouver tous les motifs approximatifs de M dans S.

Pseudo-code (graph non orienté, problème des labels uniquement)

Annotation:

Soit:

E_1 l'ensemble d'association traité

E_2 l'ensemble d'association pas encore traité

p la fonction calculant la pénalité d'un ensemble d'association comme la somme de la pénalité générée par chacune des associations

Entrée:

S: Graphe de la structure

M: Graphe du motif

n: Pénalité maximum d'arête

Sortie:

L'ensemble des occurrences possible de M dans S au degré de pénalité maximum n près

Execution:

//Initialisation

Soit R un ensemble initialisé comme vide

Soit F une file

Soit $e_0 \in E(M)$ pour chaque arête $e_s \in E(S)$:

 enfiler dans F le triplet $(\{e_0\}, \{(e_0, e_s)\}, k)$ avec $k=n-p(\{(e_0, e_s)\})$

//Développement

Tant que F n'est pas vide

 On défile un triplet (E_1, E_2, k)

 Si $E_2 = \emptyset$ et tout les noeuds de E_1 sont présents au moins deux fois dans E_1

$R \cup \{E_1\}$

 Sinon

 On prend $(e_M, e_S) \in E_2$, on pose $e_M=(u_M, v_M)$ et $e_S=(u_S, v_S)$

 Soit A_{u_M} l'ensemble des arêtes incidentes à u_M sans e_M

 Soit A_{v_M} l'ensemble des arêtes incidentes à v_M sans e_M

 Soit A_{u_S} l'ensemble des arêtes incidentes à u_S sans e_S

 Soit A_{v_S} l'ensemble des arêtes incidentes à v_S sans e_S

 Soit P le produit cartésien entre l'ensemble des injections de A_{u_M} dans A_{u_S}

 et l'ensemble des injections de A_{v_M} dans A_{v_S}

 Pour tout élément c appartenant à P

 On calcule $k_C=k-p(C)$

 Si $k_C \geq 0$

 Enfiler dans F le triplet $(E_1 \cup (e_M, e_S), (E_2 \setminus (e_M, e_S)) \cup C, k_C)$

//Fin

retourner R

On peut facilement considérer que la pénalité est un vecteur de deux entiers ce qui nous permet d'avoir une pénalité maximale correspondant au nombre d'arrête mal typé (long-range ou short-range) par rapport au motif correspondant. Alors on considère que $k_C \geq 0$ quand toutes les valeurs de k_C sont supérieures à 0.

$p(C)$ renvoie un vecteur contenant les pénalités d'étiquetage et la pénalité de typage de l'ensemble C.

Pseudo-code (graph orienté, problème des labels uniquement)

Annotation:

Soit:

f la fonction d'étiquetage

E₁ l'ensemble d'association traité

E₂ l'ensemble d'association pas encore traité

p la fonction calculant la pénalité d'un ensemble d'association comme la somme de la pénalité générée par chacune des associations

Soit e_M l'arête formée entre les sommets a et b , alors $\text{inv}(e_M)$ est l'arête formée entre les sommets b et a

Entrée:

S: Graphe de la structure orienté

M: Graphe du motif orienté

n: Pénalité maximum d'arête

Sortie:

L'ensemble des occurrences possibles de M dans S au degré de pénalité maximum n près

Execution:

//Initialisation

Soit R un ensemble initialisé comme vide

Soit F une file

Soit $e_0 \in E(M)$ pour chaque arête $e_s \in E(S)$:

 enfiler dans D le triplet $(\{\emptyset\}, \{(e_0, e_s)\}, k)$ avec $k = n - p(\{f(e_0), f(e_s)\})$

//Developpement

Tant que F n'est pas vide

 On défile un triplet (E_1, E_2, k)

 Si $E_2 = \emptyset$ et tous les noeuds de E_1 sont présents au moins deux fois dans E_1

$R \cup \{E_1\}$

 Sinon

 On prend $(e_M, e_S) \in E_2$, on pose $e_M = (u_M, v_M)$ et $e_S = (u_S, v_S)$

 Soit A_{u_M} l'ensemble des arêtes entrantes de u_M sans e_M

 Soit A_{v_M} l'ensemble des arêtes entrantes de v_M sans e_M

 Soit A_{u_S} l'ensemble des arêtes entrantes de u_S sans e_S

 Soit A_{v_S} l'ensemble des arêtes entrantes de v_S sans e_S

 Soit B_{u_M} l'ensemble des arêtes sortantes de u_M sans e_M

 Soit B_{v_M} l'ensemble des arêtes sortantes de v_M sans e_M

 Soit B_{u_S} l'ensemble des arêtes sortantes de u_S sans e_S

 Soit B_{v_S} l'ensemble des arêtes sortantes de v_S sans e_S

 Soit P le produit cartésien entre

 Le produit cartésien entre l'ensemble des injections de A_{u_M} dans A_{u_S} et
 l'ensemble des injections de A_{v_M} dans A_{v_S}

 Le produit cartésien entre l'ensemble des injections de B_{u_M} dans B_{u_S} et
 l'ensemble des injections de B_{v_M} dans B_{v_S}

Pour tout élément c appartenant à P

$k_c = k$

Pour tout éléments a de c :

On pose $a = (e_s, e_M)$

Si $\text{inv}(e_M)$ n'est pas présent dans $E_1 \cup E_2 \cup \text{iter}(c)$

$k_C = k_C - p(C)$

Sinon si $\text{inv}(e_M)$ est présente dans $E_1 \cup E_2 \cup \text{iter}(c)$ mais associée avec une autre arête que $\text{inv}(e_s)$ ou si $\text{inv}(e_s)$ est présente dans $E_1 \cup E_2 \cup \text{iter}(c)$ mais associée avec une autre arête que $\text{inv}(e_M)$

On passe au l'élément de P suivant

Si $k_C \geq 0$

Enfiler dans F le triplet $(E_1 \cup (e_M, e_s), (E_2 \setminus (e_M, e_s)) \cup C, k_C)$

//Fin

retourner R

Pseudo-code (graph orienté, problème des labels et arêtes en plus et en moins)

Annotation:

Soit:

f la fonction d'étiquetage

E₁ l'ensemble d'association traité

E₂ l'ensemble d'association pas encore traité

p la fonction calculant la pénalité d'un ensemble d'association comme la somme de la pénalité générée par chacune des associations

Soit **e_M** l'arête formée entre les sommets **a** et **b**, alors **inv(e_M)** est l'arête formée entre les sommets **b** et **a**

iter(c), le sous-ensemble des valeurs de **c** sur lesquels nous avons déjà itéré

Entrée:

S: Graphe de la structure orientée

M: Graphe du motif orienté

n₁: Pénalité maximum d'arête étiquetée différemment

n₂: Pénalité maximum d'arête étiquetée en moins

n₃: Pénalité maximum d'arête étiquetée en plus

Sortie:

L'ensemble des occurrences possibles de **M** dans **S** au degré de pénalité maximum pres (nombre d'arête différemment étiquetée, nombre d'arête en plus, nombre d'arête en moins)

Execution:

//Initialisation

Soit **R** un ensemble initialisé comme vide

Soit **F** une file

Soit **e₀** ∈ **E(M)** pour chaque arête **e_S** ∈ **E(S)**:

 enfiler dans **D** le triplet $(\{\emptyset\}, \{(e_0, e_S)\}, k)$ avec $k = n - p(\{f(e_0), f(e_S)\})$

//Developement

Tant que **F** n'est pas vide

 On défile un triplet (E_1, E_2, k)

 Si $\text{taille}(E_1 \cup E_2) \in [\text{taille}(E_M) - n_2, \text{taille}(E_M) + n_3]$ et tout les noeuds de $E_1 \cup E_2$ sont présent au moins deux fois dans E_1

 Si valide($E_1 \cup E_2, n_2, n_3$)

$R \cup \{E_1 \cup E_2\}$

 Si $\text{taille}(E_2) \neq 0$:

 On prend $(e_M, e_S) \in E_2$, on pose $e_M = (u_M, v_M)$ et $e_S = (u_S, v_S)$ tel que $\text{inv}(e_M) \notin E_1$

 Soit A_{u_M} l'ensemble des arêtes entrantes de u_M sans e_M

 Soit A_{v_M} l'ensemble des arêtes entrantes de v_M sans e_M

 Soit A_{u_S} l'ensemble des arêtes entrantes de u_S sans e_S

 Soit A_{v_S} l'ensemble des arêtes entrantes de v_S sans e_S

 Soit B_{u_M} l'ensemble des arêtes sortantes de u_M sans e_M

 Soit B_{v_M} l'ensemble des arêtes sortantes de v_M sans e_M

 Soit B_{u_S} l'ensemble des arêtes sortantes de u_S sans e_S

Soit B_{v_s} l'ensemble des arêtes sortante de v_s sans e_s

Soit P le produit carthésien entre:

-Le produit carthésien entre l'ensemble des injections de A_{UM} dans A_{US} et l'ensemble des injections de A_{VM} dans A_{US}

-Le produit carthésien entre l'ensemble des injections de B_{UM} dans B_{US} et l'ensemble des injections de B_{VM} dans B_{US}

Pour tout élément c appartenant à P

$k_c = k$

Pour tout éléments a de c :

On pose $a = (e_s, e_m)$

Si $\text{inv}(e_m)$ n'est pas présent dans $E_1 \cup E_2 \cup \text{iter}(c)$

$k_c = k_c - p(C)$

Sinon si $\text{inv}(e_m)$ est présente dans $E_1 \cup E_2 \cup \text{iter}(c)$ mais associée avec une autre arête que $\text{inv}(e_s)$ ou si $\text{inv}(e_s)$ est présente dans $E_1 \cup E_2 \cup \text{iter}(c)$ mais associée avec une autre arête que $\text{inv}(e_m)$

On passe au l'element de P suivant

Si $k_c \geq 0$

Enfiler dans F le tripler $(E_1 \cup (e_m, e_s), (E_2 \setminus (e_m, e_s) \cup C, k_c)$

//Fin

retourner R

Fonction de validation:

Entrée:

E_1 : Un ensemble d'association d'arrête du graph de la structure

S : graph de la structure

M : graph du motif

n_2 : pénalité max du nombre d'arrête en plus

n_3 : pénalité max du nombre d'arrête en moins

Sortie:

True si E_1 est un match respectant les pénalités n_2 et n_3

False si E_1 est un match respectant les pénalités n_2 et n_3

Execution:

On defini S l'ensemble des sommets v_s tels que $v_s \in E_1 \cap V(S)$ avec l'ensemble des sommets v_m tel que $v_m \in E_1 \cap V(M)$

Si un sommet v_s est associé à plusieurs sommet V_m ou inversement

retourner Faux

Sinon

pour chaque couple de somment $(v_s, v_m) \in S$:

pour chaque couple de sommet $(v'_s, v'_m) \in S \setminus \{(v_s, v_m)\}$:

si $(v_s, v'_s) \in E(S)$:

Si $(v_m, v'_m) \notin E(M)$:

$n_2 = n_2 - 1$

Si $n_2 < 0$

```

                                retourner Faux
si  $(v_s, v'_s) \notin E(S)$ :
    Si  $(v_M, v'_M) \in E(M)$ :
         $n3 = n3 - 1$ 
        Si  $n3 < 0$ 
            retourner Faux
retourner True

```